

面向多机器人协同导航的动态图神经策略： 边特征、安全过滤与密度边界

Xuelin Hu

柳州铁道职业技术学院
柳州 545000, 中国

huxuelinai@gmail.com; huxl@ltzy.edu.cn

Xiaoqin Fu*

柳州铁道职业技术学院
柳州 545000, 中国

xiaoqin.fu@qq.com; fuxiaoqin@ltzy.edu.cn

Youjing Fu

兰州大学资源环境学院
兰州 730000, 中国

fuyj2025@lzu.edu.cn

Jingchao Wang

中原工学院计算机学院
郑州 450007, 中国

static@zut.edu.cn

Abstract—多机器人共享空间导航需要同时满足目标到达、协同与避碰要求，而通信拓扑在每个控制步都会变化。本文研究共享消息传递策略能否在动态通信图上产生上述行为，并如实报告其失效边界。方法上，将机器人建模为图节点，按通信半径建立有向边，每条有向边携带由归一化相对位置、相对速度和接近速度组成的五维相对运动特征；策略以 **ORCA-style** 专家动作进行模仿学习，训练目标联合动作项、一步间距项、目标进度项与平滑项，推理阶段可选地外接两两安全过滤器。本文在四类地图、5–40 个机器人和 30 个未见测试种子上，比较 **A*** 网格跟踪、**ORCA-style** 与 **RVO-style** 局部控制器、独立 **MLP**、消息传递 **GNN**、邻域注意力 **GNN** 与 **Graph Transformer**，并在 **Wheeltec** 平台上完成 **ROS 2**、**Gazebo** 与 **RViz2** 集成验证。结果表明：消息传递相对同等容量的无边策略改善了任务完成率（10 个机器人时成功率为 0.725 对 0.425），但均值聚合 **GNN** 在主对比中并未超过独立 **MLP**，引入邻域注意力后成功率降至 0.342；带边特征的多规模训练在安全过滤下使 5–10 个机器人的目标到达率达到 0.958–0.967，但严格无物理碰撞成功率从 20 个机器人时的 0.708 降至 30 个机器人时的 0.250、40 个机器人时的 0.000。据此，本文将 10–20 个机器人判定为当前系统的实用工作区间，并将更高密度视为暴露安全瓶颈的压力测试——该瓶颈无法仅靠模仿学习消除。

关键词：多机器人系统；图神经网络；协同导航；避碰；动态交互图；ROS 2

本文提出两个问题。在观测、动作限制与终止条件完全一致的前提下，显式的局部通信图能否使学习策略优于仅观察自身节点特征的策略？通信范围与外部安全过滤器如何在目标完成率、碰撞风险与单步计算开销之间权衡？

本文贡献如下：

- 构建可复现的实验框架，在同一数据契约下统一场景生成、经典与学习型基线、训练、评估与可视化；
- 提出带五维相对运动边特征的消息传递策略、联合模仿与间距的训练目标，以及独立于策略单独消融的外部两两安全过滤器；
- 在四类地图、5–40 个机器人和 30 个未见种子上比较 **A***、**ORCA-style**、**RVO-style**、独立 **MLP**、均值聚合 **GNN**、邻域注意力 **GNN** 与 **Graph Transformer**，并开展图结构、通信半径与安全层消融；
- 在 **Wheeltec** 平台上完成 **ROS 2**、**Gazebo** 与 **RViz2** 集成，验证命名空间下的里程计、激光、速度指令与可视化话题链路。

本文不将结果表述为 **GNN** 的普遍优越性结论。部分测量结果与该结论相矛盾，第 VI 节按实测如实报告。

I. 引言

多机器人协同导航要求一组机器人在共享工作空间中从起始状态到达指定目标，且不与彼此或静态障碍物发生碰撞。相比单机器人规划，其难度体现在两方面：联合状态空间随群体规模增长；机器人与其他个体之间的相互影响随时间变化，因为邻居会持续进出感知范围。集中式联合搜索虽然精确，但可扩展性差；完全独立的局部策略则丢弃了使问题本身可解（tractable）的交互结构。

图神经网络（**GNN**）提供了一条折中路径。机器人群体可表示为一张图，其节点为机器人、边为通信关系，消息传递在节点间共享参数的同时聚合邻居信息。由于同一组权重作用于每个节点，单一策略即可服务可变数量的机器人；由于边由当前位置重建，该表示能够适应变化的拓扑。

本工作受河南省科技攻关项目（262102211055）与河南省高等学校重点科研项目（27AQ520018）资助。

* 通信作者：Xiaoqin Fu。

II. 相关工作

A. 经典与规则方法

A* 在离散栅格上进行启发式搜索，在静态地图上具有完备性，但为每个机器人单独协调路径会重新引入组合耦合 [1]。速度障碍类方法直接在速度空间中推理：若候选速度所诱导的相对运动将与邻居轨迹相交，则剔除该速度 [2]。这类方法计算廉价、几何意义清晰，但其行为强烈依赖时间窗以及智能体之间互惠性的假设。

B. 学习型多机器人避碰

去中心化深度强化学习通过依据局部观测决策免去联合搜索，但训练分布之外的密集交互仍是失效模式 [3], [4]。课程学习逐步提升受限通道的难度 [5]；物理先验被嵌入策略以鼓励安全行为 [6]；半监督变体降低了对标注的需求 [7]。船舶与编队应用表明，通信约束与形状约束可纳入同一学习问题 [8], [9]。

C. 机器人团队的图表示

Diao 等将空间关系编码为图用于路径规划 [10]; He 等将图注意力与分层运动规划结合, 以筛选真正重要的邻居 [11]。Goarin 和 Loianno 用 GNN 完成去中心化目标分配, 适合可变规模的团队, 但未处理连续避碰 [12]; Yang 等将 GNN 与 PPO 结合用于多无人机规划 [13]。综述指出该领域反复出现的张力: 规则方法可解释但脆弱, 学习方法灵活但缺乏硬性保证 [14]。

本文的设计遵循该张力所提示的折中: 图策略学习协同运动, 独立过滤器处理近距离闭合风险。两者分别消融, 并对各自报告严格物理碰撞指标, 而不把过滤后的行为归因于网络。我们同时注意到, 已有工作报告的增益往往只在单一群体规模和少量地图上得到验证; 下文的多规模压力测试正是针对这一空白。

III. 问题建模

设 $\mathcal{V} = \{1, \dots, N\}$ 为机器人集合, 机器人 i 的位置、速度与目标分别为 $p_i \in \mathbb{R}^2$ 、 $v_i \in \mathbb{R}^2$ 与 $g_i \in \mathbb{R}^2$ 。每个控制步根据通信半径 R_c 重建有向通信图:

$$A_{ij} = \begin{cases} 1, & i \neq j, \|p_i - p_j\| \leq R_c, \\ 0, & \text{其他}. \end{cases} \quad (1)$$

节点特征为 8 维: 目标相对位置、归一化速度、最近障碍物方向、最近障碍物距离以及偏置项。策略输出二维局部速度 u_i , 满足 $\|u_i\| \leq v_{\max} = 1.4 \text{ m/s}$; 位置按 $p_i^{t+1} = p_i^t + \Delta t u_i^t$ 更新, 其中 $\Delta t = 0.08 \text{ s}$ 。

全文使用两个距离阈值且二者从不混用。当任意机器人对的距离小于 $d_s = 0.72 \text{ m}$ 时记一次安全距离违规; 当任意机器人对的距离小于两个机器人半径之和 0.56 m 时记一次物理碰撞。碰撞事件在一对机器人由非违规状态转入违规状态时计数, 因此持续的相互侵入只计一次而非每步一次。任务成功要求所有机器人的最终平均目标误差低于固定阈值。

为使不同量纲的量在网络内部可比, 定义归一化算子 $\bar{x} = x/s_x$ 。对有向边 (j, i) , 使用五维特征

$$e_{ij}^t = \left[\frac{p_i^t - p_j^t}{[W, H]}, \frac{v_i^t - v_j^t}{v_{\max}}, \frac{-((v_i^t - v_j^t) \cdot \hat{r}_{ij}^t)}{v_{\max}} \right], \quad (2)$$

其中 $\hat{r}_{ij}^t = (p_i^t - p_j^t)/(\|p_i^t - p_j^t\| + \epsilon)$, $[W, H]$ 为地图尺度。最后一项为接近速度, 当两机器人正在接近时取正值, 使网络能够依据运动趋势而非仅凭瞬时距离进行判断。

IV. 方法

A. 总体架构

图 1 给出闭环流程。每个机器人对应一个图节点, 边由通信半径确定; 编码器、消息传递层与动作头在所有节点间共享参数, 因此同一策略无需重训练即可处理任意群体规模。观测由当前状态组装, 图被重建, 安全过滤器可选地对输出的速度进行修正后执行。

B. 基线方法

我们实现 A* 栅格跟踪、ORCA-style 局部排斥控制器, 以及一个无外部依赖的 RVO-style 控制器: 后者在有限的方向与速度等级格点上枚举候选速度, 并按预测邻居间距、障碍物占用与目标进度进行评分。由于该实现的作用是为各方法提供统一的实验基底, 本文称其为 RVO-style, 且不声称其等价于经过形式验证的 RVO 参考实现。独立 MLP 对每个节点施加相同的多层感知器且不接收邻接矩阵, 用以把显式交互建模的贡献与节点特征本身的贡献分离开来。

C. 消息传递策略

首先用线性层将节点特征映射为隐表示。每一层对邻居表示取平均, 并将自身状态与变换后的邻域消息拼接后更新节点:

$$m_i^{(l)} = \frac{1}{\max(1, d_i)} \sum_j A_{ij} h_j^{(l)}, \quad h_i^{(l+1)} = \sigma(W_l[h_i^{(l)} \parallel \phi_l(m_i^{(l)})]). \quad (3)$$

加入边特征后, 消息形式为

$$m_i^{(l)} = \frac{1}{\max(1, d_i)} \sum_j A_{ij} (\phi_l(h_j^{(l)}) + \psi_l(e_{ij})), \quad (4)$$

随后 $h_i^{(l+1)} = \text{ReLU}(W_l[h_i^{(l)} \parallel m_i^{(l)}])$ 。本文使用 3 层消息传递、128 个隐藏单元与共享动作头, 动作由 $\hat{u}_i = v_{\max} \tanh(f_\theta(h_i))$ 约束在可执行范围内。

D. 注意力变体

为检验邻居加权或全局自注意力是否改变结论, 我们加入两个在输入、输出、数据与测试场景上完全一致的模型。邻域注意力 GNN 将均值聚合替换为查询、键、值上的多头注意力, 仍由局部邻接矩阵掩蔽。Graph Transformer 使用多头自注意力, 以动态邻接矩阵为注意力掩码, 并配有残差连接与前馈块。二者均使用 128 个隐藏单元、4 个注意力头与共享策略头。

E. 训练目标

单纯的动作模仿能够复现专家的局部行为, 却无法保证闭环安全, 因此本文以四项损失加权和进行训练:

$$\mathcal{L} = \lambda_a \mathcal{L}_{act} + \lambda_c \mathcal{L}_{col} + \lambda_p \mathcal{L}_{prog} + \lambda_s \mathcal{L}_{smooth}, \quad (5)$$

其中 $\mathcal{L}_{act} = \frac{1}{|\mathcal{V}|} \sum_i \text{Huber}(u_i, u_i^*)$ 为模仿项。记一步预测后的机器人对距离为 $d'_{ij} = \|p_i + \Delta t u_i - p_j - \Delta t u_j\|$, 则 $\mathcal{L}_{col} = \frac{1}{N(N-1)} \sum_{i \neq j} [d_s - d'_{ij}]_+^2$ 惩罚预测间距。其余两项为

$$\mathcal{L}_{prog} = \frac{1}{N} \sum_i [\|g_i - p_i'\| - \|g_i - p_i\|]_+, \quad (6)$$

$$\mathcal{L}_{smooth} = \frac{1}{N} \sum_i \|u_i^t - u_i^{t-1}\|_2^2,$$

其中 $[x]_+ = \max(x, 0)$ 。填充节点由 $q_i \in \{0, 1\}$ 掩蔽, 故每个节点损失写作 $\sum_i q_i \ell_i / \max(1, \sum_i q_i)$, 补齐到 40 个节点的图仅在真实的机器人上训练。

多规模训练从四类地图中采样 5–40 个机器人的数据集, 并将每张图补齐到 40 个节点。目标进度项与平滑项在实践中确有作用: 单独使用间距惩罚会降低目标进度, 因此其权重必须经过调度或与 $\mathcal{L}_{prog}$ 配对使用。




Fig. 1. 动态图消息传递策略。节点特征与五维边特征进入共享的消息传递层；共享动作头输出受限的局部速度，可选的安全过滤器可对其修正。

F. 安全过滤器

策略输出动作后，过滤器检查每一对近距离机器人，在速度裁剪之前施加对称修正。令 $\delta_{ij} = p_i - p_j$, $n_{ij} = \delta_{ij} / (\|\delta_{ij}\| + \epsilon)$ 。若 $\|\delta_{ij}\| < d_s + \tau$ 且 $(u_i - u_j) \cdot n_{ij} < 0$ ，则

$$\begin{aligned} \tilde{u}_i &= u_i + \frac{\kappa_{ij}}{2} n_{ij}, \quad \tilde{u}_j = u_j - \frac{\kappa_{ij}}{2} n_{ij}, \\ \kappa_{ij} &= -(u_i - u_j) \cdot n_{ij} + [d_s + \tau - \|\delta_{ij}\|]_+, \end{aligned} \quad (7)$$

之后将每个 $\tilde{u}_i$ 裁剪至 $v_{\max}$ 。该模块仅在推理与 ROS 控制路径中启用，其效果在第 VI 节中与策略本身的效果分开报告。

V. 实验设计

实验覆盖四类地图——*crossing*、*open*、*random* 与 *narrow*——以及 5、10、20、30、40 个机器人。开发数据使用固定种子，每类 20 个回合、每回合至多 160 个时间步。冻结的主实验覆盖 $4 \times 3 \times 5 \times 10 = 600$ 个回合，包含三种机器人规模、五种方法与十个固定测试种子；扩展学习模型对比包含四种学习策略的 480 个回合；多规模测试包含 30 个未见种子（100–129）下的 1800 个安全过滤回合与 1800 个未过滤回合。所有方法共享初始状态、目标、障碍物、动作限制与终止规则。数据以压缩 NPZ 形式保存，包含特征、邻接、动作、位置、奖励、障碍物、地图、专家标识与步索引。

报告指标包括目标到达率、严格无物理碰撞成功率、安全距离违规事件、物理碰撞事件、最小机器人间距、路径长度、最终目标误差与每控制步平均计算时间。均值、标准差与 95% 置信区间均由回合级结果计算；0.72 m 的违规与 0.56 m 的物理碰撞始终分列报告。训练使用单张 24 GB GPU，批大小为 128。

VI. 实验结果

A. 主实验比较

表 I 汇总了冻结的 600 回合对比。经典控制器表现强劲：A* 全部到达目标；RVO-style 以最短路径取得 0.975–1.000 的成功率，但其控制时间随规模增长近两个数量级——5 个机器人时 7.8 ms，20 个机器人时 87.4 ms。ORCA-style 在 5 个机器人时保持最大的最小间距（0.396 m），且单步开销最低，但在部分狭窄通道中出现停滞。本表中独立 MLP 是最强的学习策略，成功率为 0.725–0.875。

均值聚合 GNN 并未超过该 MLP。它在 5、10、20 个机器人上的成功率分别为 0.625、0.725 与 0.700，碰撞事件数与 MLP 相当，而路径长度与控制时间在学习方法中最高。需要说明的是，该检查点仅在 10 个机器人的数据上训练，因此 5 与 20 个机器人的两列属于跨规模泛化结果而非同条件训练结果。我们由此得出一个范围有限但明确的结论：在该基准上，仅加入通信图并不足以超越独立策略，单凭成功率或路径长度也不能支撑优越性主张。




Fig. 2. 冻结的 600 回合评估中各方法与不同机器人规模的聚合对比。经典控制器在成功率与路径长度上占优，学习策略以完成率换取更低的单步开销。

B. 注意力与 Transformer 变体

表 II 在 480 个回合上比较了四种学习策略。总体目标到达率为 MLP 0.817、GNN 0.683、Graph Transformer 0.558、邻域注意力 GNN 0.342；在 0.56 m 物理阈值下的无碰撞成功率为 0.017、0.008、0.058 与 0.025。由此可得两点。其一，Transformer 把 GNN 的严格成功率提高约一倍，代价是约 1.6 倍的控制时间，说明表达能力有帮助，即便安全结果依然不佳。其二，以邻域掩蔽形式引入注意力反而显著变差，成功率降至 0.342、控制时间升至 1.298 ms。注意力并非免费的改进，且此处没有任何变体自身是安全的。

C. 图结构消融

去掉边即可分离出消息传递的贡献（图 3a）。10 个机器人时，局部图策略成功率为 0.725，而同等容量、无边模型的成功率为 0.425；20 个机器人时二者为 0.700 与 0.425；5 个机器人时为 0.625 与 0.500。全局图不论距离连接所有机器人对，并未优于局部图，且在 10 个机器人时更差（0.625 对 0.725）。因此消息传递确实带来了协同能力，但更稠密的图并不自动更好，且两种变体都未能消除碰撞。

D. 安全层消融

安全过滤器在 60 个回合上与原始策略单独对比（图 3b）。10 个机器人时，平均碰撞事件由 4.900 降至 0.200，平均最小间距由 0.069 m 提升至 0.794 m，但成功率由 1.000 降至 0.900。20 个机器人时碰撞事件由 27.500 降至 6.900，成功率由 0.900 降至 0.700，而最小间距仅 0.067 m，故该密度下仍未实现稳定的无碰撞到达。过滤器还会使部分机器人停滞而非改道。这一权衡十分直接：间距显著改善而任务完成率下降，这也是我们认为安全约束应进入训练而非依赖事后投影的主要原因。

E. 通信半径

更大的半径提高平均图度并提供更多邻居，代价是更多的聚合开销。10 个机器人时，2.0 m 半径仅取得 0.200 的成功率，平均度为 0.463；而 3.4 m 与 5.5 m 均达到 1.000 的成功率，平均度分别为 2.283 与 4.420；全局图取得 0.900，平均度为 9.000。5 个机器人时成功率由 2.0 m 的 0.100 单调调升至全局图的 1.000，说明稀疏图只是把小规模团队割

TABLE I

主实验比较（四类地图 × 十个固定测试种子，每格 40 个回合）。Succ 为目标成功率；Coll 为碰撞事件数，计入距离低于 0.72 m 安全阈值的状态转入次数；Sep 为最小机器人间距（m）； T 为每控制步平均计算时间（ms）。

方法	5 个机器人				10 个机器人				20 个机器人			
	Succ	Coll	Sep	T	Succ	Coll	Sep	T	Succ	Coll	Sep	T
A*	1.000	1.925	0.280	0.512	1.000	6.075	0.098	1.205	1.000	30.700	0.035	2.493
ORCA-style	0.775	1.425	0.396	0.213	0.825	3.825	0.296	0.486	0.825	13.500	0.230	1.303
RVO-style	0.975	1.825	0.294	7.779	1.000	5.575	0.131	24.941	1.000	23.325	0.062	87.373
MLP	0.725	2.575	0.191	0.342	0.850	5.400	0.095	0.483	0.875	27.400	0.038	0.775
GNN	0.625	1.850	0.224	0.683	0.725	5.675	0.149	0.828	0.700	28.675	0.041	1.129




Fig. 3. 消融实验。(a) 5、10、20 个机器人下无边、局部半径与全局连通性对比：消息传递带来了真实的协同能力，而更稠密的图并不自动更好。(b) 原始策略与过滤后策略对比，显示间距增益与成功率损失的取舍。

TABLE II

学习策略对比（480 个回合）。严格率要求到达目标且任意机器人对的距离从未低于 0.56 m 的物理直径阈值；碰撞事件为物理碰撞事件数。

模型	成功率	严格率	碰撞事件	最小间距/m	时间/ms
MLP	0.817	0.017	9.250	0.108	0.515
GNN	0.683	0.008	8.825	0.138	0.856
邻域注意力	0.342	0.025	8.167	0.259	1.298
Transformer	0.558	0.058	8.833	0.221	1.365

裂开来。各半径下控制时间均维持在 1.0 ms 附近，因此在 20 个机器人以下连通性的增益几乎免费；但全局图并未消除物理碰撞。

F. 多规模压力测试

表 III 给出 30 个未见种子上的 1800 回合安全过滤测试，这是本文信息量最大的结果。在 5–20 个机器人区间，目标到达率较高且稳定：GNN 为 0.967、0.958、0.758，Graph Transformer 为 0.983、1.000、0.842。然而严格无碰撞成功率急剧下降：GNN 从 5 个机器人时的 0.967 降至 20 个机器人时的 0.708、30 个机器人时的 0.250 与 40 个机器人时的 0.000；Graph Transformer 呈现相同形态（0.983、1.000、0.767、0.242、0.017）。每回合物理碰撞事件数从 5–10 个机器人时的 0 升至 40 个机器人时 GNN 的 6.883 与 Transformer 的 9.025，最小间距由 0.95 m 以上坍塌至约 0.4 m。控制时间随规模稳定增长，GNN 由 0.890 ms 增至 2.066 ms。

不加过滤器时情况更为严峻：GNN 在各规模下均取得 0.992–1.000 的目标到达率，但严格无碰撞成功率在 5 个机器人时仅 0.092，其余规模均为 0.000；Transformer 亦从未超过 0.117。高到达率与安全指标的近乎完全失效同时存在，这正是我们分列报告二者的原因。我们将 10–20 个机器人视为当前系统的实用工作区间，将 30–40 个机器人

TABLE III

安全过滤下的多规模测试（30 个未见种子，1800 个回合，四类地图聚合，按机器人数量索引）。严格成功率要求到达目标且不发生物理碰撞。

模型	5	10	20	30	40
目标到达率 / 严格无碰撞成功率					
GNN	0.967/0.967	0.958/0.958	0.758/0.708	0.400/0.250	0.042/0.000
Graph Transformer	0.983/0.983	1.000/1.000	0.842/0.767	0.467/0.242	0.108/0.017
每回合物理碰撞事件数					
GNN	0.000	0.000	0.075	1.158	6.883
Graph Transformer	0.000	0.000	0.217	2.267	9.025
最小间距 (m) / 控制时间 (ms)					
GNN	0.97/0.89	0.95/1.04	0.87/1.37	0.61/1.70	0.41/2.07
Graph Transformer	1.00/1.50	0.94/1.65	0.80/1.99	0.56/2.33	0.34/2.69




Fig. 4. 安全过滤下严格无碰撞成功率、最小间距与单步控制时间随群体规模的变化。目标到达率保持高位，而安全指标在 20 个机器人以上急剧崩塌。

视为压力测试：增加机器人几乎不损害目标趋近能力，却使本应保持彼此间距的机制过载。

G. 训练种子稳定性

三个独立训练的 GNN 检查点在 5、10、20 个机器人上的平均成功率分别为 0.517 ± 0.388 、 0.767 ± 0.161 与 0.850 ± 0.115 。5 个机器人处的方差足以说明只报告单个最优检查点会产生误导，也表明当前训练配置在小规模团

队上尚不稳定。上述各表均对种子与检查点取聚合，而非挑选最优运行结果。

VII. ROS 2 集成

本文提供一个 Tkinter 二维界面，可在 ORCA、RVO、A*、MLP 与 GNN 控制器之间切换，并显示机器人、目标、通信边、轨迹与实时指标。ROS 2 适配器面向 Wheeltec 模型，已在三个命名空间下的 `/robot_i/odom`、`/robot_i/scan` 与 `/robot_i/cmd_vel` 话题上完成验证；一个 Marker 节点发布 `/multi_robot/markers`，使 RViz2 可渲染机器人、目标、轨迹与通信边；启动脚本为 `ros2/run_multi_robot_gnn.sh`。上述工作验证了 Gazebo 模型上的话题契约与可视化链路，而非真实机器人行为，本文不作实机安全声明。

VIII. 局限性与结论


本文构建并评估了一个面向多机器人协同导航的动态图消息传递框架，结合多维相对运动边特征、联合模仿与间距的训练目标、外部两两安全过滤器，以及经过验证的 ROS 2 链路。测量结果支持三点结论。其一，消息传递带来了真实的协同能力：同一架构去掉边后，10 个机器人时的成功率下降约 0.30。其二，更稠密的图并不自动更好——全局图未能优于局部图。其三，也是最重要的一点，过滤与模仿相结合在 5–20 个机器人区间实现了高到达率，却无法在 30–40 个机器人时维持安全指标，严格无碰撞成功率在 40 个机器人时坍塌至接近零。

若干前提限定了上述结论。我们的 RVO-style 控制器是为实验一致性编写的有限格点方法，并非经过形式验证的 RVO 参考实现，因此与其对比应据此理解。主实验中的 GNN 检查点仅在 10 个机器人上训练，其 5 与 20 个机器人的结果属于跨规模泛化而非同条件性能。被模仿的专家本身是规则方法，策略因而继承了其局限；Gazebo 工作仅证明接口与可视化链路，而非实机行为。最后，本文基于模仿学习，带有长期目标进度与硬安全约束的强化学习微调仍不完整，而多规模结果正说明该阶段确有必要。因此，下一步工作是：以安全约束训练取代事后投影、引入经过验证的 RVO 基线、改善跨地图泛化，并在真实机器人上验证。


REFERENCES

- [1] P. E. Hart, N. J. Nilsson, and B. Raphael, “A formal basis for the heuristic determination of minimum cost paths,” *IEEE Transactions on Systems Science and Cybernetics*, vol. 4, no. 2, pp. 100–107, 1968.
- [2] P. Fiorini and Z. Shiller, “Motion planning in dynamic environments using velocity obstacles,” *The International Journal of Robotics Research*, vol. 17, no. 7, pp. 760–772, 1998.
- [3] P. Long, T. Fanl, X. Liao, W. Liu, H. Zhang, and J. Pan, “Towards optimally decentralized multi-robot collision avoidance via deep reinforcement learning,” *IEEE*, 2018, pp. 6252–6259.
- [4] N. Thumiger and M. Deghat, “A multi-agent deep reinforcement learning approach for practical decentralized uav collision avoidance,” *IEEE Control Systems Letters*, vol. 6, pp. 2174–2179, 2022.
- [5] M. M. R. Komol, B. Tidd, W. Browne, F. Maire, J. Williams, and D. Howard, “Learning behaviours for decentralised multi-robot collision avoidance in constrained pathways using curriculum reinforcement learning,” *IEEE Robotics and Automation Letters*, vol. 10, no. 8, pp. 8538–8545, 2025.
- [6] P. Feng, R. Shi, S. Wang, J. Liang, X. Yu, S. Li, and W. Wu, “Safe and efficient multi-agent collision avoidance with physics-informed reinforcement learning,” *IEEE Robotics and Automation Letters*, vol. 9, no. 12, pp. 11 138–11 145, 2024.
- [7] M. Parooei, M. T. Masouleh, and A. Kalhor, “Semi-supervised deep reinforcement learning in decentralized multi-agent collision avoidance and path planning in a complex environment,” *IEEE*, 2023.

- [8] Y. Niu, F. Zhu, M. Wei, Y. Du, and P. Zhai, “A multi-ship collision avoidance algorithm using data-driven multi-agent deep reinforcement learning,” *Journal of Marine Science and Engineering*, vol. 11, no. 11, p. 2101, 2023.
- [9] Y. Wang and Y. Zhao, “Multiple ships cooperative navigation and collision avoidance using multi-agent reinforcement learning with communication,” *Ocean Engineering*, vol. 320, p. 120244, 2025.
- [10] X. Diao, W. Chi, and J. Wang, “Graph neural network based method for robot path planning,” *Biomimetic Intelligence and Robotics*, vol. 4, no. 1, p. 100147, 2024.
- [11] X. He, X. Shi, J. Hu, and Y. Wang, “Multi-robot navigation with graph attention neural network and hierarchical motion planning,” *Journal of Intelligent & Robotic Systems*, vol. 109, no. 2, 2023.
- [12] M. Goarin and G. Loianno, “Graph neural network for decentralized multi-robot goal assignment,” *IEEE Robotics and Automation Letters*, vol. 9, no. 5, pp. 4051–4058, 2024.
- [13] Q. Yang, J. Lu, Y. Zhang, and S. Shao, “Multi-uav cooperative path planning via graph neural network and proximal policy optimization,” *IEEE Access*, vol. 13, pp. 193 575–193 588, 2025.
- [14] G. Yang, L. An, and C. Zhao, “Collision/obstacle avoidance coordination of multi-robot systems: A survey,” *Actuators*, vol. 14, no. 2, p. 85, 2025.



(a) 分地图与密度的严格成功率



(b) 典型轨迹

Fig. 5. (a) 各地图族与不同群体规模下的严格无碰撞成功率；*random* 与 *narrow* 布局在高密度下最具挑战性。(b) 典型轨迹，通信边以瞬时连线的形式绘制于半径内的机器人之间。