

面向多机器人协同导航的动态图神经策略： 边特征、安全过滤与密度边界

Xuelin Hu

柳州铁道职业技术学院
柳州 545000, 中国
huxl@ltzy.edu.cn

Jingchao Wang*

中原工学院计算机学院
郑州 450007, 中国
static@zut.edu.cn

Xiaoqin Fu

柳州铁道职业技术学院
柳州 545000, 中国
fuxiaoqin@ltzy.edu.cn

Pengming Hu

中原工学院计算机学院
郑州 450007, 中国
hupengming@zut.edu.cn

Youjing Fu

兰州大学资源环境学院
兰州 730000, 中国
fuyj2025@lzu.edu.cn

Simeng Li

柳州铁道职业技术学院
柳州 545000, 中国
lisimeng@ltzy.edu.cn

Abstract—多机器人协同导航需要在邻居关系变化和通信受限的条件下协调运动并避免碰撞。本文提出一种动态图神经策略,将机器人表示为节点,以局部通信关系建立边,通过相对位置、相对速度与接近速度构成五维边特征,并利用共享消息传递为不同规模的机器人群体生成局部速度指令。多规模策略采用混合专家模仿学习,并联合间距、目标进度与当前速度一致性损失训练,执行时由外部安全过滤器修正相互接近的机器人对的速度。实验覆盖四类地图和 5–40 个机器人,多规模测试中每种配置采用 30 个未见种子。结果表明,局部消息传递提高了相对同等容量无边策略的目标到达率;安全过滤减少了近距离冲突,并增大了最小机器人间距。在所测试的 5–10 个机器人场景中,过滤后的策略兼顾较高的无碰撞成功率与毫秒级控制时间,表明局部图交互与安全过滤适用于低至中等密度下的协同导航。

关键词: 多机器人系统; 图神经网络; 协同导航; 避碰; 动态交互图

I. 引言

多机器人协同导航要求机器人在共享空间中到达指定目标,并避免与其他机器人及静态障碍物发生碰撞。随着机器人数量增加,联合规划的计算开销增大,局部运动协调也更为困难。邻居进出感知范围还会改变机器人之间的交互关系。集中式搜索需要处理联合状态空间,而独立策略未显式建模机器人之间的关系。

图神经网络(GNN)通过机器人节点与通信边表示交互关系。消息传递用于聚合邻居信息,参数共享使同一策略能够处理不同规模的机器人群体。根据当前位置重建边,可随机器人运动更新交互结构。

本文研究局部图通信相对仅使用自身节点特征的策略对目标到达率的影响,并评估通信半径与安全过滤对碰撞风险和控制时间的作用。各方法采用相同的观测、动作限制与终止规则。

本文贡献如下:

- 设计采用相对运动边特征的动力图策略,将归一化相对位置、相对速度与接近速度组成五维边特征,通过共享消息传递建模机器人交互,支持可变规模的机器人团队;

本工作受河南省科技攻关项目(262102211055)与河南省高等学校重点科研项目(27AQ520018)资助。

* 通信作者: Jingchao Wang。

- 设计联合训练与执行方案,联合动作模仿、一步间距、目标进度与平滑损失,并在执行阶段引入可选的外部两两安全过滤器,独立评估其作用与神经策略本身的效果;
- 在四类地图、5–40 个机器人与 30 个未见种子上开展可复现验证,通过经典与神经基线对比及图结构、通信半径和安全层消融,评估机器人密度对各方法的影响。

II. 相关工作

A. 经典与规则方法

A* 通过启发式搜索在离散地图上规划路径 [1]。多机器人场景中,独立规划的路径仍需协调以避免冲突。速度障碍类方法根据预测的相对运动识别可能导致碰撞的速度 [2]。这类方法以几何关系实现局部避碰,其效果受预测时间窗和邻居运动假设的影响。

B. 学习型多机器人避碰

去中心化深度强化学习将局部观测映射为运动指令,减少对联合规划的依赖 [3], [4]。课程学习逐步增加受限通道的难度 [5]; 物理先验用于引导策略学习 [6]; 半监督方法降低标注需求 [7]。相关研究还在船舶导航中考虑了通信与编队约束 [8], [9]。

C. 机器人团队的图表示

Diao 等利用 GNN 编码空间关系以规划路径 [10]。He 等结合图注意力与分层运动规划,对邻居信息进行加权 [11]。Goarin 和 Loianno 将 GNN 用于去中心化目标分配 [12]; Yang 等结合 GNN 与 PPO 进行多无人机规划 [13]。近期综述归纳了多机器人避碰中的规则协调与学习方法 [14]。

本文采用图策略生成局部运动指令,并以独立过滤器修正相互接近的机器人对。图结构与过滤器的独立消融用于区分交互学习和动作修正的效果。四类地图、五种机器人规模的测试进一步考察这些效果随机器人密度的变化。

III. 问题建模

设 $p_i, v_i, g_i \in \mathbb{R}^2$ 分别为机器人 $i \in \mathcal{V} = \{1, \dots, N\}$ 的位置、当前速度与目标。每个控制步按以下条件连接发送节点 j 与接收节点 i :

$$A_{ij} = \mathbf{1}\{0 < \|p_i - p_j\|_2 \leq R_c\}. \quad (1)$$

该条件与实现一致，排除自环及位置完全重合的机器人对。令 $s = [W, H] = [16, 12]$ m, $v_{\max} = 1.4$ m/s, 八维节点特征为

$$x_i = [(g_i - p_i) \oslash s, v_i/v_{\max}, n_i^{\text{obs}}, \eta_i, 1], \quad (2)$$

其中 $\oslash$ 表示逐分量相除, n_i^{obs} 为最近障碍物点指向机器人的单位方向, $\eta_i = \text{clip}(d_i^{\text{obs}}/4, 0, 1)$ 。障碍物相对位移为零时方向取零; 代码将障碍距离初始化为 9 m, 未找到更近障碍物时方向保持为零。

对于边 (j, i) , 定义 $r_{ij} = p_i - p_j$, $\Delta v_{ij} = v_i - v_j$ 及 $n_{ij} = r_{ij} / \max(\|r_{ij}\|_2, \epsilon)$, 其中 $\epsilon = 10^{-6}$ 。边特征张量为

$$\begin{aligned} c_{ij} &= -\Delta v_{ij}^\top n_{ij}, \\ e_{ij} &= A_{ij} [r_{ij} \oslash s, \Delta v_{ij}/v_{\max}, c_{ij}/v_{\max}] \in \mathbb{R}^5. \end{aligned} \quad (3)$$

$c_{ij} > 0$ 表示两机器人正在接近。非边位置的特征为零, 距离和通信指示量不作为额外的边特征分量。

执行速度 u_i 满足 $\|u_i\|_2 \leq v_{\max}$ 。仿真器按 $p_i^{t+1} = \Pi_\Omega(p_i^t + \Delta t u_i^t)$ 更新位置, 其中 $\Delta t = 0.08$ s, Π_Ω 将坐标裁剪至 $\Omega = [-7.5, 7.5] \times [-5.5, 5.5]$ m。安全距离违规阈值为 $d_s = 0.72$ m, 物理碰撞阈值为机器人直径 0.56 m。事件在距离进入相应阈值内时计数, 持续违规仅计一次。任务成功要求最终平均目标误差小于 0.65 m; 严格成功还要求整个回合内无物理碰撞。

IV. 方法

A. 总体架构

图 1 展示带边特征 GNN 的推理闭环。机器人观测构成节点特征与半径图; 节点编码器及共享平均边特征编码器为三层消息传递提供输入, 每层均执行聚合与节点更新。共享动作头预测速度, 可选两两修正在范数裁剪前执行, 运动结果形成下一时刻观测。网络输入不包含候选动作列表。

B. 基线方法

基线包括 A* 栅格跟踪、ORCA-style 局部排斥控制器, 以及在有限方向与速度格点上采样的 RVO-style 控制器。RVO-style 根据预测邻居间距、障碍物占用和目标进度对候选速度评分。该控制器为本实验自行实现, 并非经过形式验证的 RVO 参考实现。独立 MLP 在机器人间共享参数, 但仅使用节点特征, 不接收邻接矩阵。

C. 消息传递策略

节点编码为 $h_i^{(0)} = \text{ReLU}(W_x x_i + b_x)$ 。令 $D_i = \max(1, \sum_j A_{ij})$, 每层首先计算邻居状态与边特征均值:

$$\bar{h}_i^{(l)} = \frac{\sum_j A_{ij} h_j^{(l)}}{D_i}, \quad \bar{e}_i = \frac{\sum_j A_{ij} e_{ij}}{D_i}. \quad (4)$$

共享边编码器作用于平均边特征, 随后执行各层的消息变换与节点更新:

$$\begin{aligned} z_i &= W_e \bar{e}_i + b_e, \\ m_i^{(l)} &= \text{ReLU}\left(W_m^{(l)} (\bar{h}_i^{(l)} + z_i) + b_m^{(l)}\right), \\ h_i^{(l+1)} &= \text{ReLU}\left(W_u^{(l)} [h_i^{(l)} \| m_i^{(l)}] + b_u^{(l)}\right). \end{aligned} \quad (5)$$

模型包含三层消息传递, 每层宽度为 128。边编码器在各层间共享; 消息变换和更新参数随层变化, 并在机器人间共享。未传入边张量时省略 z_i ; 传入全零边张量时仍保留 b_e , 孤立节点亦如此。动作头由 Linear-ReLU-Linear 构成, 输出无量纲向量 $a_i = f_{\text{head}}(h_i^{(3)})$ 。原始速度为 $u_i^{\text{raw}} = v_{\max} a_i$, 输出端无最终激活函数, 再经可选的两两修正和范数裁剪得到执行速度。

D. 注意力变体

两种注意力模型采用相同的输入、输出、数据与测试场景。邻域注意力 GNN 用查询、键、值上的多头注意力替换均值聚合, 并由局部邻接矩阵掩蔽。Graph Transformer 使用动态邻接矩阵掩蔽的多头自注意力、残差连接与前馈块。两者均使用 128 个隐藏单元、4 个注意力头和共享策略头。

E. 训练目标

训练标签为归一化专家动作 $a_i^* = u_i^*/v_{\max}$ 。训练器支持以下目标:

$$\mathcal{L} = \mathcal{L}_{\text{act}} + \lambda_c \mathcal{L}_{\text{col}} + \lambda_p \mathcal{L}_{\text{prog}} + \lambda_s \mathcal{L}_{\text{smooth}}. \quad (6)$$

对于未填充场景, $\mathcal{L}_{\text{act}} = N^{-1} \sum_{i,k} \text{SmoothL1}(a_{ik} - a_{ik}^*)$, 转折参数为 1, 两个速度分量的损失求和。令 $p'_i = p_i + \Delta t v_{\max} a_i$, $d'_{ij} = \|p'_i - p'_j\|_2$, 并记 $\gamma_i = (g_i - p_i) \oslash s$, 则

$$\begin{aligned} \mathcal{L}_{\text{col}} &= \frac{\sum_{i \neq j} [d_s - d'_{ij}]_+^2}{N(N-1)}, \\ \gamma'_i &= \gamma_i - (\Delta t v_{\max} a_i) \oslash s, \\ \mathcal{L}_{\text{prog}} &= \frac{1}{N} \sum_i [\|\gamma'_i\|_2 - \|\gamma_i\|_2]_+, \\ \mathcal{L}_{\text{smooth}} &= \frac{1}{N} \sum_i \|a_i - v_i/v_{\max}\|_2^2. \end{aligned} \quad (7)$$

其中 $[x]_+ = \max(x, 0)$ 。进度项使用归一化目标位移; 平滑项比较预测动作与记录观测中的当前归一化速度, 并非前一时刻的网络预测。训练使用未经安全过滤、速度裁剪和边界裁剪的原始预测。批训练中, 节点项按 q_{bi} 掩蔽, 并除以 $\max(1, \sum_{b,i} q_{bi})$; 机器人对的求和使用 $i \neq j$ 时的 $q_{bi} q_{bj}$, 再除以相应有效机器人对数, 不跨场景配对。

三个多规模模型的训练记录均采用 $(\lambda_c, \lambda_p, \lambda_s) = (0.5, 0.5, 0.1)$ 、种子 7 和 30 轮训练。混合专家数据按回合交替使用 ORCA-style、RVO-style 和经过安全过滤的 ORCA-style 标签, 覆盖四类地图及 5–40 个机器人, 并补齐到 40 个节点。辅助权重默认值为零, 因此上述联合目标仅据记录用于多规模实验, 不代表所有对比检查点均采用该配置。




Fig. 1. 多机器人导航流程：机器人场景与状态、结构化图输入、特征嵌入、共享 GNN 推理，以及动作输出与可选安全过滤。执行后的运动反馈形成观测-动作闭环。

F. 安全过滤器

初始化 $\tilde{u}_i = u_i^{\text{raw}}$ 。过滤器按索引顺序对每个 $i < j$ 的机器人对检查一次，并使用当前已修正的速度。令 $d_{ij} = \|r_{ij}\|_2$, $b_{ij} = (\tilde{u}_i - \tilde{u}_j)^T n_{ij}$ 。当 $d_{ij} < d_s + \rho$ 且 $b_{ij} < 0$ 时，执行

$$\alpha_{ij} = \frac{1}{2} \{-b_{ij} + k_d[d_s + \rho - d_{ij}]_+\}, \quad (8)$$

$$\tilde{u}_i \leftarrow \tilde{u}_i + \alpha_{ij} n_{ij}, \quad \tilde{u}_j \leftarrow \tilde{u}_j - \alpha_{ij} n_{ij}.$$

代码采用距离余量 $\rho = 0.35$ m，隐含比例系数为 $k_d = 1 \text{ s}^{-1}$ 。参数虽命名为 horizon，实际与距离相加，并非预测时间。遍历完成后按范数限速：

$$u_i = \tilde{u}_i \min\left(1, \frac{v_{\max}}{\max(\|\tilde{u}_i\|_2, \epsilon)}\right). \quad (9)$$

关闭过滤时，对 u_i^{raw} 直接执行相同裁剪。该方法为顺序两两速度修正，并非 ORCA 求解器，也不提供形式化无碰撞保证。过滤器仅用于执行阶段及安全专家标签生成，不进入训练损失。

V. 实验设计

实验覆盖四类地图——*crossing*、*open*、*random* 与 *narrow*——以及 5、10、20、30、40 个机器人。开发数据使用固定种子，每类 20 个回合、每回合至多 160 个时间步。主实验覆盖 $4 \times 3 \times 5 \times 10 = 600$ 个回合，包含三种机器人规模、五种方法与十个固定测试种子；扩展学习模型对比包含四种学习策略的 480 个回合；多规模测试包含 30 个未见种子（100–129）下的 1800 个安全过滤回合与 1800 个未过滤回合。所有方法共享初始状态、目标、障碍物、动作限制与终止规则。数据以压缩 NPZ 形式保存，包含特征、邻接、动作、位置、奖励、障碍物、地图、专家标识与步索引。

报告指标包括目标到达率、严格无物理碰撞成功率、安全距离违规事件、物理碰撞事件、最小机器人间距、路径长度、最终目标误差与每控制步平均计算时间。计时范围




Fig. 2. 600 回合主实验中各方法在不同机器人规模下的目标到达率、路径长度与控制时间对比。

包括观测构建与策略计算，不含安全过滤和环境更新。均值、标准差与 95% 置信区间均由回合级结果计算；0.72 m 的违规与 0.56 m 的物理碰撞始终分列报告。训练使用单张 24 GB GPU，批大小为 128。

VI. 实验结果

A. 主实验比较

表 I 汇总了 600 个回合的主实验结果。A* 在各规模下的任务成功率均为 1.000。RVO-style 的成功率为 0.975–1.000，路径最短，平均控制时间从 5 个机器人时的 7.8 ms 增至 20 个机器人时的 87.4 ms，约为原来的 11 倍。ORCA-style 在各规模下的控制时间最低，最小机器人间距最大。本组学习策略中，独立 MLP 的成功率较高，为 0.725–0.875。

均值聚合 GNN 在 5、10、20 个机器人下的成功率分别为 0.625、0.725 和 0.700，低于 MLP，但各规模下的最小机器人间距均大于 MLP。该 GNN 检查点仅使用 10 个机器人的数据训练，因此 5 和 20 个机器人的结果反映跨规模泛化能力。后续图结构消融在同一网络上比较有边与无边配置，以区分消息传递的作用。

B. 注意力与 Transformer 变体

表 II 比较了四种学习策略在 480 个回合上的表现。MLP、GNN、Graph Transformer 和邻域注意力 GNN 的目标到达

TABLE I

主实验比较（四类地图 × 十个固定测试种子，每格 40 个回合）。Succ 为目标成功率；Coll 为碰撞事件数，计入距离低于 0.72 m 安全阈值的状态转入次数；Sep 为最小机器人间距（m）；T 为每控制步平均计算时间（ms）。

方法	5 个机器人				10 个机器人				20 个机器人			
	Succ	Coll	Sep	T	Succ	Coll	Sep	T	Succ	Coll	Sep	T
A*	1.000	1.925	0.280	0.512	1.000	6.075	0.098	1.205	1.000	30.700	0.035	2.493
ORCA-style	0.775	1.425	0.396	0.213	0.825	3.825	0.296	0.486	0.825	13.500	0.230	1.303
RVO-style	0.975	1.825	0.294	7.779	1.000	5.575	0.131	24.941	1.000	23.325	0.062	87.373
MLP	0.725	2.575	0.191	0.342	0.850	5.400	0.095	0.483	0.875	27.400	0.038	0.775
GNN	0.625	1.850	0.224	0.683	0.725	5.675	0.149	0.828	0.700	28.675	0.041	1.129




Fig. 3. 5、10、20 个机器人下的消融结果。(a) 无边、局部图与全局图的目标到达率。(b) 安全过滤前后的目标到达率、安全距离违规事件与最小间距。




Fig. 4. 安全过滤下不同机器人规模的严格无碰撞成功率、最小间距与平均控制时间。机器人数量超过 20 后，无碰撞成功率下降。

TABLE II

学习策略对比（480 个回合）。严格率要求到达目标且任意机器人对的距离从未低于 0.56 m 的物理直径阈值；碰撞事件为物理碰撞事件数。

模型	成功率	严格率	碰撞事件	最小间距/m	时间/ms
MLP	0.817	0.017	9.250	0.108	0.515
GNN	0.683	0.008	8.825	0.138	0.856
邻域注意力	0.342	0.025	8.167	0.259	1.298
Transformer	0.558	0.058	8.833	0.221	1.365

率分别为 0.817、0.683、0.558 和 0.342，严格无碰撞成功率分别为 0.017、0.008、0.058 和 0.025。Graph Transformer 的严格成功率最高，平均控制时间为 1.365 ms，GNN 则为 0.856 ms。邻域注意力将平均最小间距提高至 0.259 m，但目标到达率降低，单步耗时为 1.298 ms。上述未经过滤的策略仍不足以实现可靠的无碰撞导航。

C. 图结构消融

图结构消融比较局部图、全局图与无边配置（图 3a）。10 个机器人时，局部图成功率为 0.725，同等容量的无边策略为 0.425，提高了 30 个百分点；5 和 20 个机器人时分别提高 12.5 和 27.5 个百分点。全连接未进一步改善局部通信的效果：10 个机器人时，全局图与局部图成功率分别为

0.625 和 0.725。结果表明，局部邻居信息交换有助于目标到达，但两种图策略仍存在碰撞。

D. 安全层消融

安全过滤消融在 60 个回合上比较原始 GNN 动作与修正后的动作（图 3b）。10 个机器人时，平均安全距离违规事件由 4.900 降至 0.200，平均最小间距由 0.069 m 增至 0.794 m，目标到达率由 1.000 降至 0.900。20 个机器人时，违规事件由 27.500 降至 6.900，目标到达率由 0.900 降至 0.700，平均最小间距为 0.067 m。动作修正改善了间距，但也可能阻碍目标趋近；其在 20 个机器人下的效果有限，仍需研究训练阶段的安全约束。

E. 通信半径

扩大通信半径会增加每个机器人的图邻居。10 个机器人时，2.0 m 半径对应平均度 0.463、成功率 0.200；3.4 m 和 5.5 m 半径对应平均度 2.283 和 4.420，成功率均为 1.000；全局图平均度为 9.000，成功率为 0.900。5 个机器人时，成功率由 2.0 m 半径下的 0.100 增至全局图下的 1.000。结果表明，过小半径可能限制信息交换，而局部通信范围足够后，继续增加邻居未必提高成功率。各测试配置下的控制时间约为 0.8–1.5 ms，全局连通仍未消除物理碰撞。

F. 多规模压力测试

表 III 汇总了每种配置采用 30 个未见种子的 1800 回合安全过滤测试。5 和 10 个机器人时，GNN 严格无碰撞成功率分别为 0.967 和 0.958，测试中未记录到物理碰撞；同条件下 Graph Transformer 分别为 0.983 和 1.000。20 个机器人时，GNN 与 Transformer 的目标到达率分别为 0.758 和 0.842，严格成功率分别为 0.708 和 0.767。30 和 40 个机器人时，GNN 严格成功率降至 0.250 和 0.000，Transformer 降至 0.242 和 0.017。40 个机器人时，两者每回合平均物理碰撞事件分别为 6.883 和 9.025，最小间距约为 0.4 m。GNN 平均控制时间从 5 个机器人时的 0.890 ms 增至 40 个机器人时的 2.066 ms。




Fig. 5. (a) 各地图族与不同群体规模下的严格无碰撞成功率；*random* 与 *narrow* 布局在高密度下最具挑战性。(b) 典型轨迹，通信边以瞬时连线的方式绘制于半径内的机器人之间。

TABLE III

安全过滤下的多规模测试（30 个未见种子，1800 个回合，四类地图聚合，按机器人数量索引）。严格成功率要求到达目标且不发生物理碰撞。

模型	5	10	20	30	40
目标到达率 / 严格无碰撞成功率					
GNN	0.967/0.967	0.958/0.958	0.758/0.708	0.400/0.250	0.042/0.000
Graph Transformer	0.983/0.983	1.000/1.000	0.842/0.767	0.467/0.242	0.108/0.017
每回合物理碰撞事件数					
GNN	0.000	0.000	0.075	1.158	6.883
Graph Transformer	0.000	0.000	0.217	2.267	9.025
最小间距 (m) / 控制时间 (ms)					
GNN	0.97/0.89	0.95/1.04	0.87/1.37	0.61/1.70	0.41/2.07
Graph Transformer	1.00/1.50	0.94/1.65	0.80/1.99	0.56/2.33	0.34/2.69

未加过滤时，GNN 在各规模下的目标到达率为 0.975–1.000，但严格无碰撞成功率在 5 个机器人时为 0.092，更大规模时均为 0.000；未过滤 Transformer 的严格成功率不超过 0.117。安全过滤提高了无碰撞到达率，在 5–10 个机器人下尤为明显，同时降低了目标到达率。30–40 个机器人时，过滤后策略的完成率和安全性均下降，限制了其在这些密度下的应用。

G. 训练种子稳定性

三个独立训练的 GNN 检查点在 5、10、20 个机器人下的平均成功率分别为 0.517 ± 0.388 、 0.767 ± 0.161 和 0.850 ± 0.115 。标准差由各检查点的平均成功率计算。5 个机器人下的差异最大，表明该场景对训练种子较为敏感。本项分析单独考察训练差异，前述对比则报告固定检查点在各测试回合上的平均表现。

VII. 局限性与结论

本文提出了结合相对运动边特征、联合模仿训练目标和外部安全过滤器的多机器人动态图策略。局部消息传递提高了相对同等容量无边策略的目标到达率，全局连通则未带来一致的额外收益。安全过滤增大了机器人间距，并在多规模测试的 5–10 个机器人场景中实现了较高的无碰撞成功率。GNN 在各测试规模下保持毫秒级控制时间。

实验也表明，主对比中均值聚合 GNN 的目标到达率低于独立 MLP，30–40 个机器人下的严格无碰撞成功率明显下降。主实验 GNN 仅在单一规模上训练，规则专家也限制了可供模仿的行为。RVO-style 基线采用有限候选采样，并非经过验证的 RVO 实现；当前验证仍限于仿真。后续将研究显式安全约束训练、与 RVO 参考实现的对比、跨地图泛化及真实机器人实验。

REFERENCES

- [1] P. E. Hart, N. J. Nilsson, and B. Raphael, "A formal basis for the heuristic determination of minimum cost paths," *IEEE Transactions on Systems Science and Cybernetics*, vol. 4, no. 2, pp. 100–107, 1968.
- [2] P. Fiorini and Z. Shiller, "Motion planning in dynamic environments using velocity obstacles," *The International Journal of Robotics Research*, vol. 17, no. 7, pp. 760–772, 1998.
- [3] P. Long, T. Fanl, X. Liao, W. Liu, H. Zhang, and J. Pan, "Towards optimally decentralized multi-robot collision avoidance via deep reinforcement learning," *IEEE*, 2018, pp. 6252–6259.
- [4] N. Thumiger and M. Deghat, "A multi-agent deep reinforcement learning approach for practical decentralized uav collision avoidance," *IEEE Control Systems Letters*, vol. 6, pp. 2174–2179, 2022.
- [5] M. M. R. Komol, B. Tidd, W. Browne, F. Maire, J. Williams, and D. Howard, "Learning behaviours for decentralised multi-robot collision avoidance in constrained pathways using curriculum reinforcement learning," *IEEE Robotics and Automation Letters*, vol. 10, no. 8, pp. 8538–8545, 2025.
- [6] P. Feng, R. Shi, S. Wang, J. Liang, X. Yu, S. Li, and W. Wu, "Safe and efficient multi-agent collision avoidance with physics-informed reinforcement learning," *IEEE Robotics and Automation Letters*, vol. 9, no. 12, pp. 11 138–11 145, 2024.
- [7] M. Parooei, M. T. Masouleh, and A. Kalhor, "Semi-supervised deep reinforcement learning in decentralized multi-agent collision avoidance and path planning in a complex environment," *IEEE*, 2023.
- [8] Y. Niu, F. Zhu, M. Wei, Y. Du, and P. Zhai, "A multi-ship collision avoidance algorithm using data-driven multi-agent deep reinforcement learning," *Journal of Marine Science and Engineering*, vol. 11, no. 11, p. 2101, 2023.
- [9] Y. Wang and Y. Zhao, "Multiple ships cooperative navigation and collision avoidance using multi-agent reinforcement learning with communication," *Ocean Engineering*, vol. 320, p. 120244, 2025.
- [10] X. Diao, W. Chi, and J. Wang, "Graph neural network based method for robot path planning," *Biomimetic Intelligence and Robotics*, vol. 4, no. 1, p. 100147, 2024.
- [11] X. He, X. Shi, J. Hu, and Y. Wang, "Multi-robot navigation with graph attention neural network and hierarchical motion planning," *Journal of Intelligent & Robotic Systems*, vol. 109, no. 2, 2023.
- [12] M. Goarin and G. Loianno, "Graph neural network for decentralized multi-robot goal assignment," *IEEE Robotics and Automation Letters*, vol. 9, no. 5, pp. 4051–4058, 2024.
- [13] Q. Yang, J. Lu, Y. Zhang, and S. Shao, "Multi-uav cooperative path planning via graph neural network and proximal policy optimization," *IEEE Access*, vol. 13, pp. 193 575–193 588, 2025.
- [14] G. Yang, L. An, and C. Zhao, "Collision/obstacle avoidance coordination of multi-robot systems: A survey," *Actuators*, vol. 14, no. 2, p. 85, 2025.